

Artículo 3. Almacén de datos y lakehouse

Mazumdar, D., Hughes, J., y Onofré, J. B. *The Data Lakehouse: Data Warehousing and More*. Preprint, arXiv:2310.08697. <https://arxiv.org/abs/2310.08697>

1. Problema. Los almacenes de datos relacionales para análisis (RDBMS-OLAP) están pensados sobre todo para datos estructurados, generan copias difíciles de controlar, guardan datos en formatos propietarios y son costosos. Los data lakes resuelven parte de esto, pero combinarlos con un almacén en dos niveles añade complejidad. Los autores argumentan que un lakehouse ofrece las capacidades del almacén de datos y del data lake juntas, y más.

2. Datos. Es un artículo conceptual y no parte de un conjunto de datos real. Como ejemplo, una tabla de abandono de clientes se guarda en formato Parquet en Amazon S3, se gestiona con Apache Iceberg, se cataloga con Project Nessie y se consulta con Dremio Sonar. El tratamiento propuesto es ELT: primero cargar los datos crudos (schema-on-read) y luego transformarlos por capas (física, de preparación, de negocio y de aplicación).

3. Modelado. El modelado de datos es una práctica independiente de la tecnología, y el lakehouse admite esquemas en estrella y copo de nieve. El artículo menciona integridad referencial, gestión de datos maestros y dimensiones de cambio lento (tipos 2 y 4), pero no define entidades ni hechos propios porque no hay un dominio concreto.

4. Preguntas que responde. Permite tableros de inteligencia de negocio, consultas ad hoc en SQL y entrenamiento de modelos de aprendizaje automático sobre la misma copia de los datos. En el ejemplo, un tablero y un clasificador de abandono con exactitud de 0.877.

5. Limitaciones y trabajo futuro. No hay una sección de limitaciones. Reconocen que el ejemplo es un marco básico y que la complejidad y las herramientas varían en implementaciones grandes. Tampoco plantean trabajo futuro explícito. Conviene notar que los autores trabajan para Dremio, cuyos productos aparecen en el ejemplo.